

# Supervisor Progress Summary

## Project

---

Healthcare Data Imputation Using Machine Learning with Genetic Algorithm-Based Feature Selection.

## Completion status

---

The project is complete for the defined single-dataset scope. The repository contains the executed experiment outputs, validated analysis, report-data package, literature review, and final academic report draft.

## Work completed

---

- Selected and integrity-checked the UCI Heart Failure Clinical Records dataset (299 rows, 12 features, binary `DEATH_EVENT`, no natural missing values).
- Implemented leakage-safe splitting, MCAR/MAR/MNAR masking at 10%, 20%, and 30%, and ground-truth-preserving reconstruction scoring.
- Implemented mean, median, KNN, and IterativeImputer methods.
- Completed the 180-run multi-seed prediction matrix.
- Implemented GA feature selection and completed the nine-cell imputation-plus- GA sweep.
- Completed 27 paired statistical comparisons and a three-cell multi-seed GA replication subset.
- Verified 15 literature entries, prepared report assets, and drafted the final academic report.

## Defensible findings

---

Missingness measurably reduced prediction performance in 4 of 9 complete-data comparisons (paired t-test,  $p < 0.05$ ). No imputer or missingness mechanism was statistically distinguishable from its alternatives at five seeds. GA produced a stable feature-reduced subset, consistently selecting `time` and `ejection_fraction`, but did not reliably improve prediction after replication. The `time` feature remains a documented leakage-adjacent modelling caveat.

## Remaining limitations

---

The primary dataset is small, only five seeds were used, and the E6 imputation-plus-GA replication covers three of nine cells across three seeds. These are reported limitations, not hidden gaps. Full details and future work are in `docs/final_report.md`.

## Deliverables

---

- Final report: `docs/final_report.md`
- Report assets: `report_data/`
- Reproducibility audit: `docs/reproducibility_audit.md`
- Source pipeline: `src/`
- Experiment runners: `experiments/`

- Tests: [tests/](#)

## Key Result Tables

### Four-way comparison (E0 / E1-E3 / E5 / E6)


| mechanis | missing | imputer   | feature_c | complete           | complete           | complete           | complete           | imputed            | imputed            | imputed            | imputed            | ga_rf_roc_auc      |
|----------|---------|-----------|-----------|--------------------|--------------------|--------------------|--------------------|--------------------|--------------------|--------------------|--------------------|--------------------|
| MAR      | 10      | knn       | 6         | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 |
| MAR      | 20      | knn       | 8         | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 |
| MAR      | 30      | knn       | 5         | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 |
| MCAR     | 10      | knn       | 7         | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 |
| MCAR     | 20      | iterative | 11        | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 |
| MCAR     | 30      | iterative | 7         | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 |
| MNAR     | 10      | median    | 6         | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 |
| MNAR     | 20      | median    | 2         | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 |
| MNAR     | 30      | iterative | 4         | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 | 0.6666666666666667 |

### GA feature selection frequency (5 runs)

| feature                  | selection_count | selection_frequency |
|--------------------------|-----------------|---------------------|
| time                     | 5               | 1.0                 |
| ejection_fraction        | 5               | 1.0                 |
| serum_creatinine         | 4               | 0.8                 |
| diabetes                 | 3               | 0.6                 |
| serum_sodium             | 2               | 0.4                 |
| platelets                | 2               | 0.4                 |
| anaemia                  | 2               | 0.4                 |
| creatinine_phosphokinase | 1               | 0.2                 |
| sex                      | 1               | 0.2                 |
| high_blood_pressure      | 1               | 0.2                 |
| smoking                  | 1               | 0.2                 |
| age                      | 0               | 0.0                 |

## Key Figures

### Four-way comparison



GA feature selection frequency

